

# תרגיל בית 1

## שאלה 1

יהי  $X_n \sim X_n \sim \mathcal{N}\left(0, \frac{1}{n}\right)$   
 $F_X(x) = \begin{cases} 0 & x < 0 \\ 1 & x \geq 0 \end{cases}$   
 האם  $X_n \xrightarrow{\mathcal{D}} X$ ? אם  $X_n \xrightarrow{P} X$ ?

## שאלה 2

יהו  $[0, \theta]$  דגימות p.i.

- א. רשמו את המודל הסטטיסטי הפרמטרי של הנתונים.
- ב. מצאו  $\hat{\theta}_n$  אומד נראות מרבית ל- $\theta$ .
- ג. מצאו  $bias$ ,  $se$  ו- $MSE$  ל- $\hat{\theta}_n$ .
- ד. האם  $\hat{\theta}_n$  עקיב? הסבירו.
- ה. בחנו את פונקציית הצפיפות של האומד. האם היא שואפת לפונקציית הצפיפות של התפלגות נורמלית כאשר  $n \rightarrow \infty$ ? חזו על ההוכחה לגבי נורמליות אסימפטוטית של אומדי נראות מירבית (שיעור 2.7). ציינו הנחה אחת עליה הטעסה ההוכחה שלא מתקינה במקרה זה.

## שאלה 3

הוכחו את הטענות הבאות:

- א. עבור  $(\lambda)$ ,  $X_1, X_2, \dots, X_n \sim Poisson(\lambda)$  הממוצע המדגמי  $\hat{\lambda}_n = \frac{1}{n} \sum_{i=1}^n X_i$  הוא אומד נראות מרבית ל- $\lambda$
- ב.  $MSE_{\theta_0}(\hat{\theta}_n) = (bias_{\theta_0}(\hat{\theta}_n))^2 + Var_{\theta_0}(\hat{\theta}_n)$
- ג.  $I(\theta) = \mathbb{E}[s^2(X; \theta)] = -\mathbb{E}\left[\frac{\partial}{\partial \theta} s(X; \theta)\right]$

## שאלה 4

הוכחו את הטענות הבאות

- א. הוכחו כי אם אומד  $\hat{\theta}_n$  הוא נורמלי אסימפטוטית אז הוא בהכרח עקיב. ניתן להניח ללא הוכחה כי  $se(\hat{\theta}_n) \xrightarrow{n \rightarrow \infty} 0$ .
- ב. עברו על ההוכחה של עקיבות אומד נראות מירבית (הרצאה 2.5) והוכחו את טענות העזר 1,2,3 המופיעות בחלק מההוכחה בשקף 25 ביחידת השקפים של חטיבה 2.



# שאלה 1

$$F_X(x) = \begin{cases} 0 & x < 0 \\ 1 & x \geq 0 \end{cases}$$

יהי  $X_n \sim \mathcal{N}\left(0, \frac{1}{n}\right)$  ויהי  $X$  מ"מ מההתפלגות

$$\text{האם } ?X_n \xrightarrow{\mathcal{D}} X \text{ האם } ?X_n \xrightarrow{P} X$$

$$\lim_{n \rightarrow \infty} P(|X_n - X| > \varepsilon) = 0$$

$\forall \varepsilon > 0 \quad \text{sic} \quad X_n \xrightarrow{P} X$

$$P(X \leq x) = \begin{cases} 0 & x < 0 \\ 1 & x \geq 0 \end{cases}$$

$$P(X \leq x) = 1$$

$x \geq 0 \quad \text{sic} \quad X \equiv 0 \quad \text{sic}$

$$P(|X_n - X| > \varepsilon) =$$


$\varepsilon, \text{sic}$

$$= P(|X_n| > \varepsilon) =$$

$$= 1 - P(|X_n| < \varepsilon) =$$

$$= 1 - P(-\varepsilon < X_n < \varepsilon) =$$

$$\begin{aligned}
&= 1 - P(-\sqrt{n}\varepsilon < \sqrt{n}X_n < \sqrt{n}\varepsilon) = \\
&= 1 - \left[ P(\sqrt{n}X_n < \sqrt{n}\varepsilon) - P(\sqrt{n}X_n < -\sqrt{n}\varepsilon) \right] \\
&\downarrow \quad \sqrt{n}X_n \sim N(0, 1) \\
&= 1 - \left[ \Phi(\sqrt{n}\varepsilon) - \Phi(-\sqrt{n}\varepsilon) \right] = \\
&= 1 - \left[ \Phi(\sqrt{n}\varepsilon) - (1 - \Phi(\sqrt{n}\varepsilon)) \right] = \\
&= 1 - [2\Phi(\sqrt{n}\varepsilon) - 1] \xrightarrow{n \rightarrow \infty} 1 - 1 = 0
\end{aligned}$$



## שאלה 2


יהו  $[0, \theta]$  דגימות p.i.i.

- רשמו את המודל הסטטיסטי הפרמטרי של הנתונים.
- מצאו  $\hat{\theta}_n$  אומד נראות מרבית ל- $\theta$ .
- מצאו bias ו-MSE ל- $\hat{\theta}_n$
- אם  $\hat{\theta}_n$  עקייב? הסבירו.
- בחנו את פונקציית הצפיפות של האומד. האם היא שואפת לפונקציית הצפיפות של התפלגות נורמלית באשר  $\theta \rightarrow \infty$ ? חזרו על ההוכחה לגבי נורמליות אסימפטוטית של אומדי נראות מירביה (שיעור 2.7). ציינו הנחה אחת עליה התבססה ההוכחה שלא מתקיים במקורה זה.

$$L(\theta) = \mathcal{F} = \left\{ \frac{1}{\theta}, \theta \in \mathbb{R}_+ \right\} \quad (2)$$

$$\log \prod_{i=1}^n f_i(\theta) = \log \frac{1}{\theta^n} = -n \log \theta \quad \text{where } \theta \geq \max\{x_i; i \in \mathbb{N}\} \quad (3)$$

$$\Rightarrow \hat{\theta}_n = X_{(n)}$$



$$\underset{\theta}{\operatorname{bias}}(\hat{\theta}_n) = E_{\theta}(\hat{\theta}_n) - \theta = E_{\theta}(X_{(n)}) - \theta = \theta \left( \frac{n-n-1}{n+1} \right) = \frac{-\theta}{n+1} \quad (2)$$

$$* E(X_{(n)}) = \frac{1}{\theta^n} \cdot \int_0^\theta x \cdot x^{n-1} dx = \frac{1}{\theta^n} \cdot \frac{x^{n+1}}{n+1} \Big|_0^\theta = \theta \cdot \frac{n}{n+1}$$

$$F_{X_{(n)}} = \begin{cases} 0 & x < 0 \\ \left(\frac{x}{\theta}\right)^n & 0 \leq x \leq \theta \\ 1 & x > \theta \end{cases} \Rightarrow f_{X_{(n)}}(x) = \frac{d}{dx} F_{X_{(n)}}(x) = \frac{1}{\theta} n \cdot \theta^{n-1} x^{n-1} \Big|_0^\theta = \frac{n}{n+1} \theta^{n-1}$$

$$\begin{aligned} \operatorname{Var}(X_{(n)}) &= E(X_{(n)}^2) - E(X_{(n)})^2 = \frac{1}{\theta^n} \int_0^\theta x^2 \underbrace{x^{n-1}}_{x^{n+1}} dx + \theta \cdot \frac{n}{n+1} \\ &= \frac{-1}{\theta} \frac{x^{n+2}}{n+2} \Big|_0^\theta + \frac{\theta n}{n+1} = \frac{\theta^2 \cdot n}{n+2} + \frac{\theta n}{n+1} = \frac{n \cdot \theta^2}{(n+2)(n+1)^2} \end{aligned}$$

$$\Rightarrow \text{se} = \sqrt{\operatorname{Var}(X_{(n)})} = \sqrt{\frac{n \theta^2}{(n+2)(n+1)^2}}$$

$$\Rightarrow \text{MSE}_{\hat{\theta}_n}(\theta) = \frac{2\theta^2}{(n+1)(n+2)} \xrightarrow{n \rightarrow \infty} 0 \Rightarrow \text{asymptotic} \hat{\theta}_n \quad (2)$$

$$f(k | \theta) = n \cdot \frac{k^{n-1}}{\theta^n} \xrightarrow{n \rightarrow \infty} 0 \quad \text{if } 0 < k < \theta$$

$\xrightarrow{n \rightarrow \infty} \infty, k = \theta$

$$S(x_i; \hat{\theta}_n) = \frac{\partial \log(f(x_i; \theta))}{\partial \theta} \Big|_{\theta=\hat{\theta}_n} = \frac{1}{\hat{\theta}_n} \sum_{j=1}^n S(x_j; \theta) = 0 \quad \text{if } \hat{\theta}_n > 0$$

### שאלה 3

הוכיחו את הטענות הבאות:

א. עבור  $\hat{\lambda}_n = \frac{1}{n} \sum_{i=1}^n X_i$ , הממוצע המדגמי  $X_1, \dots, X_n \sim Poisson(\lambda)$  הוא אומד נראות מרבית ל- $\lambda$ .

$$MSE_{\theta_0}(\hat{\theta}_n) = \left( bias_{\theta_0}(\hat{\theta}_n) \right)^2 + Var_{\theta_0}(\hat{\theta}_n)$$

$$I(\theta) = \mathbb{E}[s^2(X; \theta)] = -\mathbb{E}\left[\frac{\partial}{\partial \theta} s(X; \theta)\right]$$

$$\hat{\lambda}_n = \frac{1}{n} \sum_{i=1}^n X_i, \quad X_1, \dots, X_n \sim Poisson(\lambda) \quad (\text{k})$$

$$\lambda = 8 \text{ נס"ע} \quad \hat{\lambda}_n = 8 \text{ נס"ע}$$

$$L_n(x_i; \theta) = \prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} = \lambda^{x_1} e^{-\lambda} \cdot \lambda^{x_2} e^{-\lambda} \cdot \lambda^{x_3} e^{-\lambda} \cdots \lambda^{x_n} e^{-\lambda}$$

$$= \frac{\lambda^{x_1} e^{-\lambda}}{x_1!} \cdot \frac{\lambda^{x_2} e^{-\lambda}}{x_2!} \cdot \frac{\lambda^{x_3} e^{-\lambda}}{x_3!} \cdots \frac{\lambda^{x_n} e^{-\lambda}}{x_n!}$$

$$= \frac{\lambda^{\sum x_i} e^{-n\lambda}}{\prod_{i=1}^n x_i!}$$

$$\ln(L_n(\theta)) = \log(\lambda^{\sum x_i}) + \log(e^{-n\lambda})$$

$$- \log(\prod_{i=1}^n x_i!) =$$

$$= \sum x_i \cdot \log(\lambda) - n\lambda - \log(\prod x_i!)$$

$$l_n'(\theta) = \sum_i x_i - n = 0$$

$$\Rightarrow \hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n x_i \quad \blacksquare$$

$$l_n''(\theta) = \sum - \frac{x_i}{\lambda^2} < 0 \Rightarrow \text{min}_{\theta} l_n(\theta)$$

$$MSE_{\theta_0}(\hat{\theta}) = \mathbb{E}[(\hat{\theta}_n - \theta_0)^2] = \quad (\text{a})$$

MSE of estimator

$$= \text{Var}(\hat{\theta}_n - \theta_0) + \mathbb{E}(\hat{\theta}_n - \theta_0)^2$$

$$\text{Var}(x) = \mathbb{E}(x^2) - \mathbb{E}(x)^2$$

$$\text{Var}(c) = 0 \quad \downarrow \quad \text{Var}(\hat{\theta}_n) + (\mathbb{E}(\hat{\theta}_n) - \theta_0)^2 =$$

$$\mathbb{E}[c] = c$$

$$= \text{Var}(\hat{\theta}_n) + \left( \text{bias}_{\theta_0}(\hat{\theta}_n) \right)^2 \quad \blacksquare$$

bias of estimator

$$I(\theta) = \text{Var}_{\theta}(s(x; \theta)) = \quad (\text{d})$$

$$= \mathbb{E}[s(x; \theta)^2] - \underbrace{\mathbb{E}[s(x; \theta)]^2}_{= 0}$$

$$= \mathbb{E}[s^2(x; \theta)]$$

$$\mathbb{E}[s^2(x; \theta)] = -\mathbb{E}\left[\frac{\partial}{\partial \theta} s(x; \theta)\right] \quad \text{so } \partial/\partial \theta \text{ is 100}$$

$$\frac{\partial}{\partial \theta} \left( \frac{1}{f(x; \theta)} \cdot \frac{\partial f(x; \theta)}{\partial \theta} \right) = \frac{\partial}{\partial \theta} \left( \frac{\frac{\partial f(x; \theta)}{\partial \theta}}{f(x; \theta)} \right)$$

$$= \frac{\partial^2 f(x; \theta)}{\partial \theta^2} \cdot f(x; \theta) - \frac{\partial f(x; \theta)}{\partial \theta} \cdot \frac{\partial f(x; \theta)}{\partial \theta}$$

$f^2(x; \theta)$

$$= \frac{\partial^2 f(x; \theta)}{\partial \theta^2} \cdot \frac{1}{f(x; \theta)} - \left( \frac{\frac{\partial f(x; \theta)}{\partial \theta}}{f(x; \theta)} \right)^2$$

\*

nsgn log de

$$= \overbrace{\frac{\partial^2 f(x; \theta)}{\partial \theta^2} \cdot \frac{1}{f(x; \theta)}}^* - \left( \frac{\frac{\partial}{\partial \theta} \log f(x; \theta)}{\log f(x; \theta)} \right)^2$$

$$\frac{\partial}{\partial \theta} \log f(x; \theta) = s(x; \theta) \quad \text{so } \partial/\partial \theta$$

: fapji \* n log f(x; \theta) so f(x; \theta)

$$\begin{aligned}
& - \mathbb{E} \left[ \frac{\partial^2 f(x; \theta)}{\partial \theta^2} \cdot \frac{1}{f(x; \theta)} \right] = \\
& = - \int \frac{\partial^2 f(x; \theta)}{\partial \theta^2} \cdot \frac{1}{f(x; \theta)} \cdot dF(x) = \\
& = - \int \frac{\partial^2 f(x; \theta)}{\partial \theta^2} \cdot \frac{f(x; \theta)}{\cancel{f(x; \theta)}} \cdot dx = \\
& = - \frac{\partial^2}{\partial \theta^2} \underbrace{\int f(x; \theta) dx}_{= 1} = 0
\end{aligned}$$

$$\begin{aligned}
& - \mathbb{E} \left[ - \underbrace{\left( \frac{\partial}{\partial \theta} \log f(x; \theta) \right)^2}_{s(x; \theta)} \right] = \mathbb{E}[s^2(x; \theta)]
\end{aligned}$$

$$\mathbb{E}[-s'(x; \theta)] = \mathbb{E}[s^2(x; \theta)]$$

$$I(\theta) = \mathbb{E}[s^2(x; \theta)] = \mathbb{E}[-s'(x; \theta)]$$

$$\frac{\hat{\theta}_n - \theta_0}{\text{se}(\hat{\theta}_n)} \xrightarrow{d} N(0, 1)$$

גא. אסמן:

(lc 4)

$$\hat{\theta}_n \xrightarrow{P} \theta$$

• ס"ג

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| > \varepsilon) = 0 \iff$$

$$= 1 - \lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \varepsilon) =$$

$$= 1 - \lim_{n \rightarrow \infty} P(-\varepsilon < \hat{\theta}_n - \theta < \varepsilon) =$$

$$= 1 - \lim_{n \rightarrow \infty} P\left(-\frac{\varepsilon}{\text{se}(\hat{\theta}_n)} < \frac{\hat{\theta}_n - \theta_0}{\text{se}(\hat{\theta}_n)} < \frac{\varepsilon}{\text{se}(\hat{\theta}_n)}\right) =$$

$$= 1 - \lim_{n \rightarrow \infty} \left[ P\left(\frac{\hat{\theta}_n - \theta_0}{\text{se}(\hat{\theta}_n)} < \frac{\varepsilon}{\text{se}(\hat{\theta}_n)}\right) - P\left(\frac{\hat{\theta}_n - \theta_0}{\text{se}(\hat{\theta}_n)} < -\frac{\varepsilon}{\text{se}(\hat{\theta}_n)}\right) \right]$$

$$= 1 - \lim_{n \rightarrow \infty} \left[ \bar{\Phi}\left(\frac{\varepsilon}{\text{se}(\hat{\theta}_n)}\right) - \left(1 - \bar{\Phi}\left(\frac{-\varepsilon}{\text{se}(\hat{\theta}_n)}\right)\right) \right] =$$

$$= 1 - \lim_{n \rightarrow \infty} \left[ 2 \underbrace{\bar{\Phi}\left(\frac{\varepsilon}{\text{se}(\hat{\theta}_n)}\right)}_{\downarrow \text{se}(\hat{\theta}_n) \xrightarrow{n \rightarrow \infty} 0} - 1 \right] =$$

$$= 1 - 1 = 0$$

(n)(4)

1.  $\mathbb{E}_{\theta_0}[s(x, \hat{\theta}_n)] \xrightarrow{n \rightarrow \infty} 0$  means that  $\hat{\theta}_n \xrightarrow{P} \theta_0$ .

$\theta_0$  ასევე  $\mathbb{E}_{\theta_0}[s(x; \theta)]$  დე ვიგრძელოთ დავვიტოვთ

$$\mathbb{E}[s(x; \hat{\theta}_n)] \approx \underbrace{\mathbb{E}[s(x; \theta_0)]}_{\substack{\text{Assumption 3} \leftrightarrow \\ \text{pag 24}}} + \frac{\partial}{\partial \theta} \mathbb{E}_{\theta_0}[s(x; \theta)] \Big|_{\theta=\theta_0} (\hat{\theta}_n - \theta_0) + R$$

Assumption 3  $\leftrightarrow$   
pag 24

$$\text{შევ 2 უნიკალური } \frac{\frac{\partial^2 \mathbb{E}[l(x; \theta)]}{\partial \theta^2}}{\partial \theta} = \frac{\partial \mathbb{E}_{\theta_0}[s(x; \theta)]}{\partial \theta} \Big|_{\theta=\theta_0}$$

სრულ ასიმული დანართი 3 უნიკალური და  $\frac{\partial^2 \mathbb{E}[l(x; \theta)]}{\partial \theta^2} \Big|_{\theta=\theta_0} < 0$  არის დანართი 2 უნიკალური და  $\frac{\partial \mathbb{E}_{\theta_0}[s(x; \theta)]}{\partial \theta} \Big|_{\theta=\theta_0} > 0$

სა და  $\mathbb{E}[s(x; \hat{\theta}_n)] \xrightarrow{n \rightarrow \infty} 0$  არის დანართი

$$\frac{\partial}{\partial \theta} \mathbb{E}_{\theta_0}[s(x; \theta)] \Big|_{\theta=\theta_0} \cdot (\hat{\theta}_n - \theta_0) \xrightarrow{n \rightarrow \infty} 0$$

$$\hat{\theta}_n - \theta_0 \xrightarrow{n \rightarrow \infty} 0$$

$$\hat{\theta}_n \xrightarrow{P} \theta_0$$

ცენტრალური  
განვითარებული

$$2. \frac{1}{n} \sum_{i=1}^n s(X_i, \hat{\theta}_n) = \frac{1}{n} \sum_{i=1}^n \left. \frac{\partial}{\partial \theta} \log f(X_i, \theta) \right|_{\theta=\hat{\theta}_n}$$

מינימיזציה  
 $\ell(\theta) = \sum_{i=1}^n \log f(X_i; \theta)$

מינימום נאכלי ב- $\hat{\theta}_n$   
 (24. סעיף מינימום נאכלי).

$$f' \quad \left. \frac{\partial \ell(\theta)}{\partial \theta} \right|_{\theta=\hat{\theta}_n} = 0$$

מינימום נאכלי ב- $\hat{\theta}_n$   
 (24. סעיף מינימום נאכלי).

$$\frac{1}{n} \sum_{i=1}^n s(X_i, \hat{\theta}_n) = \frac{1}{n} \sum_{i=1}^n \left. \frac{\partial \ell(X_i; \theta)}{\partial \theta} \right|_{\theta=\hat{\theta}_n} = 0$$

$$3. \text{ Claim: } \frac{1}{n} \sum_{i=1}^n s(X_i, \theta) \xrightarrow{P} \mathbb{E}_{\theta_0}[s(X, \theta)]$$

הdelta iid נורם  $X_i \sim N(\mu, \sigma^2)$   $s(X_1, \theta), \dots, s(X_n, \theta)$   
 $\mathbb{E}[s(X, \theta)]$  מוגדרת כ- $s(X_i, \theta)$   
 מינימום נאכלי ב- $\hat{\theta}_n$  מוגדר ב- $\hat{\theta}_n$

$$\frac{1}{n} \sum_{i=1}^n s(X_i, \theta) \xrightarrow{P} \mathbb{E}_{\theta_0}[s(X, \theta)]$$